

ANEXOS

Anexo A: Correos de prueba

A continuación se presentan los tres correos que se analizaron para el punto 2. Las palabras clave aparecen en **negrita**.

Correo 1 (spam)

Asunto: **Felicitaciones** por tu suerte

Hola, quería decirte que eres el **ganador** del sorteo de la empresa Fantasía S.L. Te aseguro que recibirás el **premio** de **dinero** de **inmediato**. Solo envía tus **datos** para completar el proceso. No pierdas la oportunidad, actúa ahora mismo. Saludos cordiales.

Correo 2 (legítimo)

Asunto: Confirmación de tu pedido en Solara Textil

Te confirmamos que tu pedido ha sido procesado correctamente y el **pago** se ha registrado sin incidencias. Te enviamos la **factura** detallada para que la revises y la guardes en tu archivo. Si tienes cualquier duda sobre las **políticas** de devolución, puedes consultarlas en la sección de ayuda. Recuerda que tu **comunidad** de clientes accede a un **descuento** adicional en la próxima temporada. Agradecemos tu confianza y esperamos que disfrutes tu nueva prenda.

Correo 3 (legítimo)

Asunto: Alerta de seguridad: actividad inusual detectada

Te contactamos para informarte sobre una actividad **urgente** relacionada con tu **cuenta**. Recuerda que nunca pediremos tus **datos** por este medio. Por tu seguridad, no hagas **clic** en enlaces desconocidos. También debes tener presente que nunca compartas tu **contraseña** con nadie. Confirma tus operaciones directamente desde la app oficial de Bancos Virtuales.

Anexo B: Conjunto de entrenamiento y estimación de probabilidades

El conjunto que se generó contiene 200 correos sintéticos, de los cuales 120 son spam y 80 son legítimos, que deberían tener 21 palabras divididas en típicas de spam, típicas de correos legítimos, y ambiguas (cuyo significado depende de las que las rodean). Se decidió además fijar de antemano la proporción de correos de cada clase que contendrían cada palabra (columna “Diseño”) para comprobar si se recuperaban los valores dentro del experimento.

Adicionalmente, se aplicó normalización de texto para evitar que caracteres especiales, tildes, mayúsculas, símbolos, y otros, pudieran distorsionar el análisis.

Finalmente, se aplicó el suavizado de Laplace (Kandala, 2023), estimando la verosimilitud de cada palabra como la proporción de correos de la clase que la contienen, sumando 1 al conteo y 2 al total:

$$P(w \mid \text{clase}) = \frac{n_{\text{clase}}(w) + 1}{N_{\text{clase}} + 2}$$

Este ajuste permite que, en caso de que exista una palabra que nunca haya aparecido y que tendría una probabilidad 0, no anule el producto del resto de palabras. Además, se suma 2 al denominador porque únicamente existen dos resultados: que la palabra aparezca o no aparezca. Por ejemplo, "ganador" aparece en 50 de los 120 correos spam y en 1 de los 80 legítimos:

$$P(\text{ganador} \mid \text{Spam}) = \frac{50 + 1}{120 + 2} = 0,418$$

$$P(\text{ganador} \mid \text{Ham}) = \frac{1 + 1}{80 + 2} = 0,024$$

La razón de verosimilitud, $P(w | \text{Spam}) / P(w | \text{Ham})$, dice que tan más probable es que una palabra esté en spam que en un correo legítimo. Si es mayor a 1, indica cuántas veces más probable es la palabra en spam que en correos legítimos: mayor que 1 se va hacia a spam, menor que 1, va hacia legítimo, y cerca de 1 no aporta evidencia.

Tabla B1. Verosimilitudes estimadas para las 21 palabras del vocabulario (ordenadas por razón)

Palabra	Tipo	n spam	n ham	P(w Spam)	P(w Ham)	Razón	Diseño (spam / ham)
urgente	Spam	33	0	0,2787	0,0122	22,85	0,35 / 0,05
felicitaciones	Spam	28	0	0,2377	0,0122	19,49	0,30 / 0,04
ganador	Spam	50	1	0,4180	0,0244	17,14	0,35 / 0,02
premio	Spam	34	1	0,2869	0,0244	11,76	0,35 / 0,04
dinero	Spam	34	1	0,2869	0,0244	11,76	0,30 / 0,03
exclusivo	Spam	29	2	0,2459	0,0366	6,72	0,25 / 0,05
gratis	Spam	56	5	0,4672	0,0732	6,39	0,40 / 0,06
inmediato	Spam	37	3	0,3115	0,0488	6,39	0,30 / 0,04
regalo	Spam	24	4	0,2049	0,0610	3,36	0,25 / 0,05
datos	Ambigua	45	18	0,3770	0,2317	1,63	0,30 / 0,25
clic	Ambigua	35	16	0,2951	0,2073	1,42	0,30 / 0,20
cuenta	Neutra	45	29	0,3770	0,3659	1,03	0,35 / 0,35
contraseña	Ambigua	17	13	0,1475	0,1707	0,86	0,20 / 0,15
factura	Neutra	26	24	0,2213	0,3049	0,73	0,25 / 0,25
pago	Neutra	26	25	0,2213	0,3171	0,70	0,25 / 0,25
descuento	Neutra	19	25	0,1639	0,3171	0,52	0,20 / 0,20
políticas	Legítima	3	14	0,0328	0,1829	0,18	0,04 / 0,25
equipo	Legítima	4	23	0,0410	0,2927	0,14	0,05 / 0,30
comunidad	Legítima	4	26	0,0410	0,3293	0,12	0,03 / 0,30
informe	Legítima	2	16	0,0246	0,2073	0,12	0,03 / 0,30
reunión	Legítima	2	28	0,0246	0,3537	0,07	0,02 / 0,30

Al verificar el calculo de las razones, se puede observar que el simulador respetó el diseño: las nueve palabras que se utilizaron como spam dieron razones entre 3,4 y 22,9, mientras que las legítimas entre 0,07 y 0,18.

Anexo C: Cálculos detallados con Markov de orden 0

Para cada uno de los correos, se multiplican las verosimilitudes de sus palabras clave en cada una de las clases (spam y ham), luego se multiplica cada uno de esos productos por el prior de su clase, $P(\text{Spam}) = 0,6$ y $P(\text{Ham}) = 0,4$, y se normaliza dividiendo spam entre la suma de ambos.

Correo 1

Palabra	P(w Spam)	P(w Ham)	Razón
felicitaciones	0,2377	0,0122	19,49
ganador	0,4180	0,0244	17,14
premio	0,2869	0,0244	11,76
dinero	0,2869	0,0244	11,76
inmediato	0,3115	0,0488	6,39
datos	0,3770	0,2317	1,63

$$\prod P(w | Spam) = 9,60 \times 10^{-4} \quad \prod P(w | Ham) = 2,00 \times 10^{-9}$$

$$Spam: 0,6 \times 9,60 \times 10^{-4} = 5,76 \times 10^{-4}$$

$$Ham: 0,4 \times 2,00 \times 10^{-9} = 8,00 \times 10^{-10}$$

$$P(Spam | correo) = \frac{5,76 \times 10^{-4}}{5,76 \times 10^{-4} + 8,00 \times 10^{-10}} > 99,99\% \Rightarrow \text{Spam (correcto)}$$

Correo 2

Palabra	P(w Spam)	P(w Ham)	Razón
pago	0,2213	0,3171	0,70
factura	0,2213	0,3049	0,73
políticas	0,0328	0,1829	0,18
comunidad	0,0410	0,3293	0,12
descuento	0,1639	0,3171	0,52

$$\prod P(w | Spam) = 1,08 \times 10^{-5} \quad \prod P(w | Ham) = 1,85 \times 10^{-3}$$

$$Spam: 0,6 \times 1,08 \times 10^{-5} = 6,47 \times 10^{-6}$$

$$Ham: 0,4 \times 1,85 \times 10^{-3} = 7,38 \times 10^{-4}$$

$$P(Spam | correo) = \frac{6,47 \times 10^{-6}}{6,47 \times 10^{-6} + 7,38 \times 10^{-4}} = 0,87\% \Rightarrow \text{Legítimo (correcto)}$$

Correo 3

Palabra	P(w Spam)	P(w Ham)	Razón
urgente	0,2787	0,0122	22,85
cuenta	0,3770	0,3659	1,03
datos	0,3770	0,2317	1,63
clic	0,2951	0,2073	1,42
contraseña	0,1475	0,1707	0,86

$$\prod P(w | Spam) = 1,72 \times 10^{-3} \quad \prod P(w | Ham) = 3,66 \times 10^{-5}$$

$$Spam: 0,6 \times 1,72 \times 10^{-3} = 1,03 \times 10^{-3}$$

$$Ham: 0,4 \times 3,66 \times 10^{-5} = 1,46 \times 10^{-5}$$

$$P(Spam | correo) = \frac{1,03 \times 10^{-3}}{1,03 \times 10^{-3} + 1,46 \times 10^{-5}} = 98,61\% \Rightarrow \text{Spam (falso positivo)}$$